

Departamento de Ciencia de la Computación
Universidad de Ingeniería y Tecnología (UTEC)

**Proyecto #2: Sistema Generativo Interactivo para Variaciones
Visuales con Feedback Humano y Explicación mediante Agentes
de IA**

Curso: Planificación y Toma de Decisiones en IA

Profesora: Dra. Aurea Soriano-Vargas

Integrantes: Mauricio Alvares, David Torres, Marcelo Zuloeta, Juan Diego Prochazka

1. Definición del Problema y Diseño del Sistema


1.1 Contexto y caso de uso

El proyecto aborda el problema de la selección asistida de variaciones visuales en flujos de trabajo de fotografía de retrato profesional. En este contexto, fotógrafos y diseñadores deben evaluar múltiples versiones procesadas de una misma imagen para elegir el estilo más adecuado al encargo del cliente. Este proceso es inherentemente subjetivo, consume tiempo considerable y rara vez queda documentado de forma reproducible.

El sistema propuesto convierte esta tarea en un flujo estructurado de decisión humano-IA: el usuario carga una imagen de retrato, el sistema genera cinco variaciones estilísticas distintas, el usuario acepta o rechaza cada una con retroalimentación opcional en texto libre, y un agente sintetiza el proceso en una explicación coherente. El resultado es un flujo auditable que combina la capacidad generativa del modelo con el criterio del usuario.


1.2 Objetivos y restricciones

El sistema tiene tres objetivos principales: generar exactamente cinco variaciones visuales por imagen de entrada con estilos perceptualmente diferenciados; registrar de forma estructurada cada decisión de aceptación o rechazo junto con la justificación textual opcional del usuario; y producir una explicación coherente con las decisiones registradas mediante un agente de explicabilidad. La restricción central es que el sistema solo procesa imágenes en las que se confirma la presencia de un rostro mediante detección facial previa a la generación. Abajo un diagrama del flujo esperado de un usuario:



1.3 Diseño general del sistema

El sistema se organiza en cuatro módulos con flujo lineal de información. El módulo generativo recibe la imagen de entrada y produce las cinco variaciones aplicando diferentes combinaciones de estilo, semilla y parámetros de difusión. La interfaz gráfica presenta las variaciones al usuario en tarjetas individuales con controles de aceptación/rechazo y campos de texto libre. El módulo de registro almacena las decisiones en formato JSON estructurado. Finalmente, el agente de explicabilidad lee el log de decisiones y genera un resumen textual que describe qué variaciones fueron seleccionadas y por qué, priorizando la retroalimentación escrita del usuario sobre los metadatos técnicos del modelo. Abajo un diagrama de la arquitectura:



2. Selección y Preparación de Datos

2.1 Dataset del sistema: retratos con consentimiento

Para las sesiones de usuario, el sistema opera sobre retratos con consentimiento explícito o licencia verificada. Esta decisión fue guiada por consideraciones éticas fundamentales: la generación de variaciones de retratos humanos implica riesgos de manipulación de identidad, por lo que el uso de imágenes sin consentimiento explícito quedó descartado desde el diseño. La política del repositorio (finetuning.yaml, ethics.md) prohíbe expresamente el scraping de imágenes o el uso de datos con derechos de autor inciertos. Los directorios locales están segmentados en buckets consented/ y licensed/ según esta política. No se utiliza ningún dataset público scrapeado como fuente activa.

2.2 Datasets de preentrenamiento de los modelos base

Los modelos generativos que el sistema utiliza fueron preentrenados sobre datasets de gran escala cuyas características son relevantes para entender el comportamiento y los sesgos del sistema.

Stable Diffusion v1.5 (runwayml/stable-diffusion-v1-5), que opera como backend local por defecto, fue entrenado sobre LAION-2B(en), un subconjunto del dataset LAION-5B

compuesto por más de cinco mil millones de pares imagen-texto extraídos de la web pública. El checkpoint v1.5 fue inicializado desde los pesos de SD v1.2 y luego fine-tuneado durante 595,000 pasos a resolución 512×512 sobre el subconjunto LAION-Aesthetics v2 5+, que filtra imágenes con puntaje estético superior a 5. LAION-2B(en) está compuesto casi exclusivamente de descripciones en inglés, lo que implica que imágenes de culturas que utilizan otros idiomas están insuficientemente representadas, traduciéndose en una tendencia del modelo a establecer estéticas occidentales como referencia por defecto, sesgo documentado en la model card oficial.

SDXL-Turbo (stabilityai/sd-xl-turbo), utilizado como backend en el endpoint Modal para generación rápida, es una versión destilada de SDXL 1.0 mediante Adversarial Diffusion Distillation (ADD). ADD combina destilación por puntuación con una pérdida adversarial que asegura alta fidelidad de imagen con un número mínimo de pasos de muestreo, permitiendo generar imágenes en 1 a 4 pasos con calidad comparable a modelos que requieren 50 pasos. Por heredar los pesos de SDXL 1.0, SDXL-Turbo hereda también sus datasets de preentrenamiento, que incluyen LAION-Aesthetics y subconjuntos relacionados de LAION-5B.

Una implicación importante de ambos modelos es que LAION-5B ha sido objeto de controversia significativa: investigadores encontraron que contenía material ilegal, millones de imágenes con derechos de autor, y descripciones con lenguaje de odio. Aunque el subconjunto Aesthetics filtra por puntuación estética, no aplica filtros de consentimiento ni de representación demográfica.

2.3 Pipeline de preprocesamiento

prepare_portrait_dataset.py implementa un pipeline de siete pasos. Primero aplica corrección EXIF y conversión a RGB. A continuación aplica un filtro de tamaño mínimo que descarta imágenes con resolución insuficiente. El tercer paso es la detección facial obligatoria: las imágenes sin rostro detectable son rechazadas automáticamente. El cuarto paso aplica un filtro de proporción facial (face_padding, min_face_ratio, max_face_ratio según finetuning.yaml) que descarta rostros demasiado pequeños o que ocupen la totalidad del encuadre. El quinto paso mide la nitidez mediante varianza Laplaciana (blur_variance_min) y elimina imágenes borrosas. Finalmente, se realiza un crop cuadrado centrado en el rostro con relleno proporcional, redimensionamiento con interpolación Lanczos, y guardado en JPG a calidad 94. No se aplican augmentations ni normalización a tensores en esta etapa, ya que la normalización ocurre internamente en el modelo de difusión durante la inferencia.

3. Implementación del Modelo Generativo

3.1 Nivel de implementación y modelos utilizados

El sistema implementa un nivel avanzado híbrido. El flujo de producción combina rutas locales de difusión con rutas API, y la planificación de estilos para el path API es dinámica: un LLM genera los cinco estilos distintos en cada ejecución en lugar de leer una lista fija. Se soportan cuatro backends de generación: Stable Diffusion 1.5 en ejecución local sobre GPU (ruta CUDA); la API de OpenAI con el modelo gpt-image-2 a través del endpoint images/edits; servicios alternativos como Modelslab y Hugging Face; y un endpoint Modal configurado con stabilityai/sd-xl-turbo para generación acelerada, que fue el backend activo en la sesión de demostración documentada en este informe. El backend activo se selecciona mediante el selector de modo en la interfaz.

3.2 Estrategia de variación

La generación de las cinco variaciones opera en dos capas. En la primera capa, para el path API, un LLM planifica cinco estilos distintos dinámicamente en cada ejecución


(generator.py), produciendo para cada uno un prompt descriptivo, seed_offset, strength y guidance_scale propios. En la segunda capa, durante la fase de refinamiento, un segundo paso LLM genera prompts ajustados a partir de las decisiones aceptadas y las notas del usuario, produciendo una ronda adicional de variaciones alineadas con el criterio expresado. En el path local y Modal, la diferenciación se mantiene por combinación de prompt de estilo, seed offset, denoising strength y guidance scale por variación, con steps calculados de forma balanceada antes de enviar el request al servicio Modal. Un postproceso de mitigación de artefactos verdes se aplica sobre las salidas en generator.py.

A modo de referencia, la configuración utilizada en la sesión de demostración documentada fue la siguiente:

Estilo	Denoising Strength	Guidance Scale	Seed Offset	Descripción del prompt
Natural lighting	0.54	8.2	+1	Retrato lifestyle con luz diurna de alta clave, fondo crema aireado
Cinematic tint	0.66	9.0	+2	Retrato cinematográfico de bajo contraste, sombras teal y luces ámbar
Studio headshot	0.52	8.6	+3	Headshot comercial con doble softbox y fondo gris sin costuras
Editorial polish	0.68	9.2	+4	Retrato editorial de moda con gradación de color premium
Soft luxury retouch	0.58	8.4	+5	Campaña de belleza con iluminación clamshell y piel luminosa

Los estilos con mayor denoising strength (0.66–0.68) producen mayor divergencia estilística respecto a la imagen original; los de menor strength (0.52–0.54) preservan en mayor medida la composición y la identidad. En el endpoint Modal con SDXL-Turbo se utilizan 4 pasos de inferencia; en difusión local se utilizan 28 pasos.

Ejemplo de una generacion desde cero:



Ejemplo de imagenes generadas:




4. Interfaz e Interacción Humano-IA

4.1 Diseño de la interfaz

studio-shell.tsx implementa un layout de escritorio de dos columnas. El panel izquierdo concentra los controles de generación: área de carga de imagen, selector de modo (Preview / API Studio / Fine-tuned Studio / GPU Studio), toggle de face-lock que activa el condicionamiento IP-Adapter, campo de semilla base, botón de generación y panel de estado del runtime con información del hardware detectado. El panel derecho está dedicado a la revisión: en la parte superior muestra el preview de la imagen original junto con studio notes contextuales y botón de guardado; en la parte inferior presenta las cinco tarjetas de variación, cada una con la imagen generada, los metadatos del estilo (provider, strength, seed), los botones Keep y Pass, y un campo de texto libre para justificar la decisión.

Ejemplo de refinamiento:



4.2 Registro estructurado de decisiones

El sistema valida y almacena exactamente cinco decisiones por sesión (**schemas.py**). Cada entrada incluye el identificador de variación (variation_id, entero en rango 1–5), la decisión binaria (decision: "accepted" o "rejected") y la justificación textual opcional del usuario (reason). La siguiente tabla corresponde a la sesión real documentada en este informe (session_id: 20260627-190101-572a693a), generada con el backend Modal-API, seed base 4200 y face preservation deshabilitado:

Variación	Estilo	Decisión	Razón del usuario
#1	Natural lighting	accepted	"Looks overly young, but expression is on point"
#2	Cinematic tint	rejected	—
#3	Studio headshot	accepted	"Expression is good"
#4	Editorial polish	rejected	"Too grumpy"
#5	Soft luxury retouch	accepted	—

Esta sesión ilustra el valor del campo de razón: la variación #1 fue aceptada a pesar de una observación negativa sobre el aspecto ("overly young"), porque la expresión fue considerada correcta. La variación #4 fue rechazada por criterio expresivo ("Too grumpy"), no estilístico, lo que el agente de explicabilidad debe capturar fielmente en su resumen.

5. Generación de Explicaciones y Evaluación del Sistema

5.1 Arquitectura del agente de explicabilidad

El agente de explicación opera en dos modos configurables. El modo por defecto es un motor de reglas determinista (**rules-v1**, implementado en explainer.py) que genera el resumen a partir del log JSON sin depender de ninguna API externa, garantizando coherencia perfecta con las decisiones registradas. El modo opcional delega la generación al modelo **meta-llama/llama-4-scout-17b-16e-instruct** a través de la API de Groq, produciendo explicaciones más naturales y con mayor capacidad de síntesis, al costo de

introducir cierto riesgo de alucinación si el contexto JSON es ambiguo o incompleto. El resumen de refinamiento —correspondiente a la segunda ronda de generación— es explícitamente LLM-driven, ejecutado a través de `explain_refinement_with_metadata` en `explainer.py` e invocado desde `main.py`.

5.2 Diseño del prompt

El sistema utiliza dos templates de prompt relevantes. El primero, para el resumen de decisiones, instruye al modelo a actuar como motor de explicación fiel que utiliza únicamente los hechos del JSON proporcionado sin inventar datos, tratando los campos `reason` del usuario como evidencia primaria y los metadatos técnicos como contexto de soporte; el `user prompt` solicita un párrafo conciso anclado en los comentarios del usuario cuando están presentes. El segundo template, el planificador dinámico de estilos API, instruye al LLM a generar cinco objetos de estilo distintos y perceptualmente diferenciados para retrato, cada uno con nombre de estilo, prompt descriptivo, `strength`, `guidance_scale` y `seed_offset`, en formato JSON estricto sin preámbulo.

Aplicado a la sesión documentada, el agente produce una explicación que captura: que la expresión fue el criterio dominante de selección (variaciones #1 y #3 aceptadas por expresión, #4 rechazada por expresión); que el estilo cinematográfico (#2) fue descartado sin comentario explícito; y que la variación #5 fue aceptada sin objeción.

5.3 Métricas de evaluación

`evaluate_portrait_outputs.py` implementa cuatro métricas cuantitativas. El **Diversity Score** se calcula como uno menos el SSIM promedio entre todos los pares posibles de las cinco variaciones: un valor cercano a 1 indica alta diversidad perceptual, mientras que uno cercano a 0 indica variaciones casi idénticas. La **Face Detection Rate** mide la proporción de variaciones en las que se detecta un rostro, funcionando como proxy de coherencia de retrato tras la generación. Cabe señalar que en la sesión documentada el campo `detected_faces` registró 0 en todas las variaciones a pesar de que los rostros son visibles en las imágenes generadas, lo que sugiere una limitación del detector empleado en modo API o un umbral de confianza demasiado estricto. El **Same Identity Rate** es un proxy de similaridad de identidad respecto a la imagen original. Finalmente, el sistema calcula un indicador binario de **Gate Pass/Fail** que resume si la sesión supera los umbrales mínimos de calidad. No hay reporte de benchmark consolidado en el snapshot actual del repositorio.

5.4 Análisis crítico y limitaciones

El sistema presenta cinco limitaciones principales. Primera, el detector facial presenta falsos negativos en el modo API, invalidando la métrica Face Detection Rate para ese modo de operación. Segunda, aunque el path API genera estilos dinámicamente, el espacio de variación del path local sigue siendo predefinido en `generation.yaml`. Tercera, el motor de reglas garantiza coherencia pero produce explicaciones formulaicas; el modo Llama-4-Scout mejora la naturalidad pero introduce riesgo de alucinación. Cuarta, los resultados numéricos consolidados de evaluación no estaban disponibles en el snapshot actual del repositorio. Quinta, el planificador dinámico de estilos LLM podría amplificar o mitigar los sesgos heredados de los modelos base dependiendo del modelo utilizado, pero esto no ha sido auditado.

6. Consideraciones Éticas

El sistema opera en el dominio de retratos humanos, lo que impone obligaciones éticas abordadas de forma explícita durante el diseño.

Consentimiento de datos. La política del sistema prohíbe el uso de imágenes scrapeadas o con derechos de autor inciertos. Solo se utilizan retratos con consentimiento o licencia verificada, lo que contrasta deliberadamente con los datasets de preentrenamiento de los

modelos base: LAION-5B, fuente común de SD 1.5 y SDXL-Turbo, ha sido cuestionado por presencia de material ilegal, imágenes con derechos de autor, y ausencia de mecanismos de opt-in o opt-out para los sujetos fotografiados.

Riesgo de manipulación de identidad. Las variaciones con denoising strength alto pueden alterar significativamente la apariencia de una persona. El sistema no incluye actualmente mecanismos de marcado de agua ni detección de deepfakes, lo que representa una brecha de seguridad a subsanar antes de cualquier despliegue en producción.

Sesgos del modelo. El repositorio reconoce en [ethics.md](#) los riesgos de sesgo en estilo, iluminación y representación inherentes a modelos entrenados sobre LAION, en particular la tendencia a establecer estéticas occidentales como referencia. Estos sesgos no han sido auditados cuantitativamente en el proyecto actual, lo que constituye una limitación explícita a subsanar en iteraciones futuras.

Explicabilidad y uso institucional. El diseño del agente de explicabilidad prioriza la voz del usuario sobre la racionalización técnica del modelo, lo que reduce el riesgo de justificaciones opacas. En contextos de uso institucional, el sistema debe operar bajo políticas de uso explícitas que descarten aplicaciones de riesgo como la suplantación de identidad o la generación de material atribuido falsamente a personas reales.